ĐẠI HỌC BÁCH KHOA HÀ NỘI
VIỆN CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

Chương 1
Tổng quan về lưu trữ và xử lý dữ liệu lớn

GV: TS. Trần Văn Đặng
(dangtv@soict.hust.edu.vn)

1

1

Thông tin chung về môn học

Tên học phần:	**Lưu trữ và xử lý dữ liệu lớn**
Mã số học phần:	IT4931
Khối lượng:	3(2-2-0-6)

Dữ liệu lớn yêu cầu cần có các cơ chế, kỹ thuật xử lý dữ liệu ở quy mô lớn và hiệu quả. Học phần này nhằm cung cấp cho người học các kiến thức về công nghệ lưu trữ dữ liệu lớn, các hệ quản trị cơ sở dữ liệu NoSQL, NewSQL, các nguyên lý xử lý dữ liệu song song, phân tán, theo khối, theo luồng, xử lý sự kiện phức tạp, quản lý luồng công việc. Bên cạnh đó, người học được làm quen và vận dụng các công nghệ xử lý dữ liệu lớn trên nền tảng Hadoop - Map Reduce, và Spark. Sau khi kết thúc học phần này người học có khả năng hiểu, lựa chọn, cài đặt, và vận hành các giải pháp lưu trữ và xử lý dữ liệu phù hợp dựa trên các kiến thức học được cho các bài toán ứng dụng cụ thể liên quan tới dữ liệu lớn

2

Điểm quá trình

- Project: 75~85% (including coding, report, representation)
  - Teamwork : 3-4 students/group
  - Topics : to be defined
- Lab exercises: 15~25%
- Điểm danh

Teams

- Teams code: **4ul0uhh**

Lịch học (dự kiến)

Week	Bài giảng
1	**Tổng quan về lưu trữ và xử lý dữ liệu lớn**
2	**Hệ sinh thái Hadoop (Hadoop ecosystem)**
3	**Hệ thống tập tin phân tán Hadoop HDFS** Hoàn thành đăng ký nhóm, bài tập lab 1
4	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 1** Tổng quan
5	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 2** Kiến trúc phân tán phổ biến, hoàn thành đăng ký đề tài bài tập lớn
6	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 3** Truy vấn SQL trên NoSQL, trình bày bài tập lab 1
7	**Hệ thống truyền thông điệp phân tán**
8	**Cơ sở dữ liệu phi quan hệ NoSQL - phần 3** Elasticsearch
9	**Nghỉ giữa kỳ**

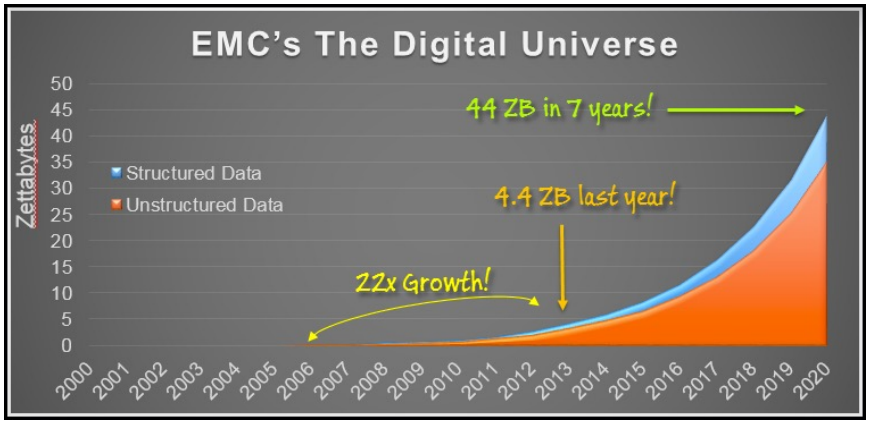
5

Lịch học (dự kiến)

Week	Bài giảng
10	**Các kĩ thuật xử lý dữ liệu lớn theo khối - phần 1** Map Reduce
11	**Các kĩ thuật xử lý dữ liệu lớn theo khối - phần 2** Apache Spark, bài tập lab 2
12	**Các kĩ thuật xử lý luồng dữ liệu lớn** Spark Streaming, trình bày bài tập lab 2
13	**Các kĩ thuật xử lý luồng dữ liệu lớn** Spark Streaming
14	**Phân tích dữ liệu lớn** Spark ML, Kibana
15	**Kiến trúc dữ liệu lớn** Lambda architecture
16	Bảo vệ bài tập lớn
17	Bảo vệ bài tập lớn
18	Bảo vệ bài tập lớn

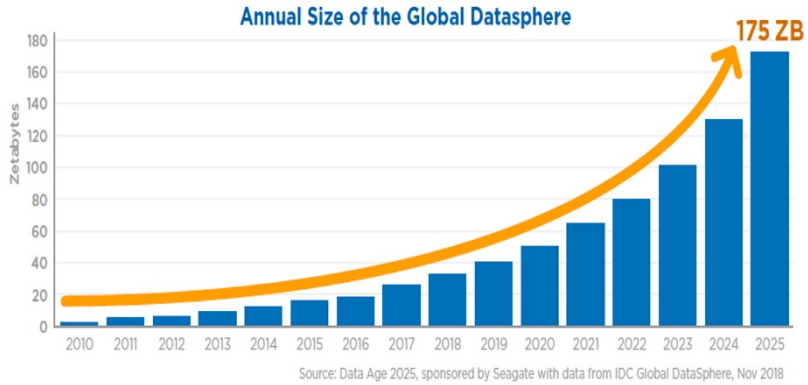
6

Tổng dung lượng dữ liệu 2020



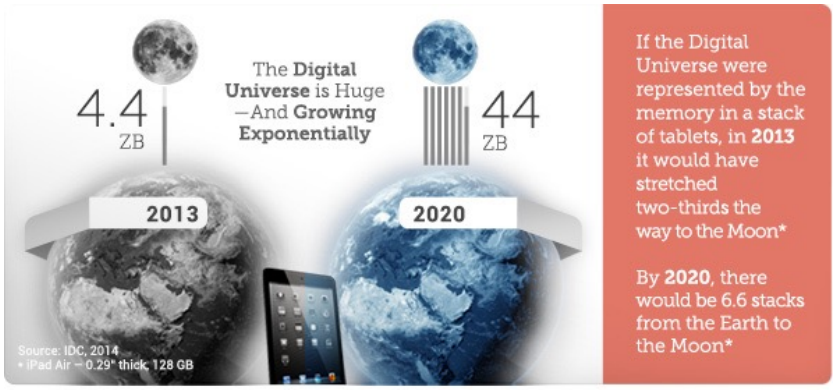
7

Tổng dung lượng dữ liệu 2025



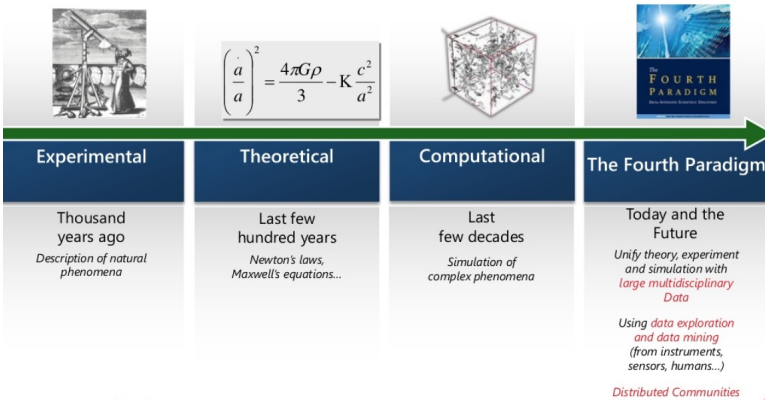
8

Hình dung về độ lớn của dữ liệu



9

Khoa học dữ liệu: Bước phát triển thứ 4 của khoa học khám phá



10

Nói về dữ liệu lớn năm 2008

http://www.wired.com/wired/issue/16-07 September 2008



11

Nói về dữ liệu lớn năm 2014



THE AVERAGE PERSON TODAY PROCESSES MORE DATA IN A SINGLE DAY THAN A PERSON IN THE 1500'S DID IN AN ENTIRE LIFETIME

LOOK TO THE LEFT, and you see Times Square at dusk. Look to the right, and you see the same location at midmorning. Internationally acclaimed photographer Stephen Wilkes's time-altering image of New York's Times Square is part of his body of work titled *Day to Night*.

The image was created by blending more than 1,400 separate photos taken over the course of 15 hours—a meticulous process that took him nearly three months.

PHOTO: STEPHEN WILKES

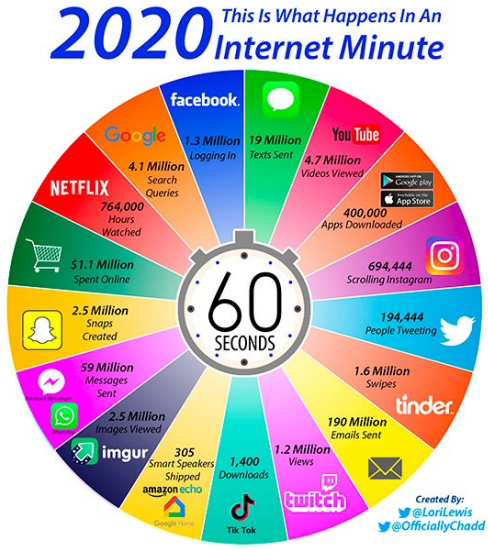
12

Dữ liệu lớn ngày nay



13

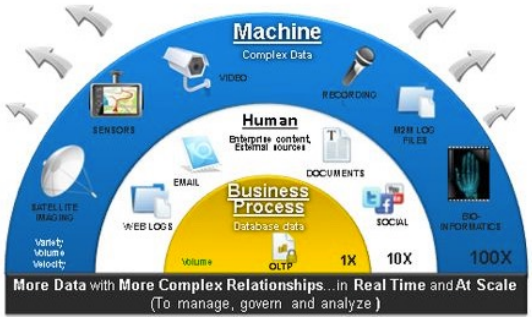
Những con số về tốc độ sinh dữ liệu



14

Các nguồn tạo ra dữ liệu lớn

- Thương mại điện tử
- Mạng xã hội
- Internet vạn vật (IoT)
- Các thử nghiệm dữ liệu lớn (tin sinh học, vật lý lượng tử, vvv)



15

Dữ liệu được ví như nguồn tài nguyên dầu mỏ mới

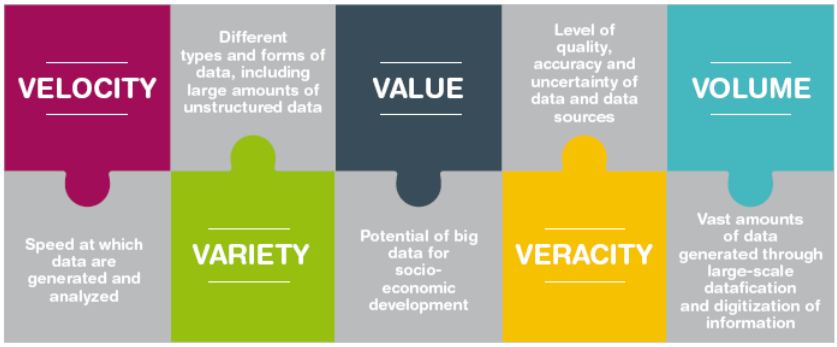






16

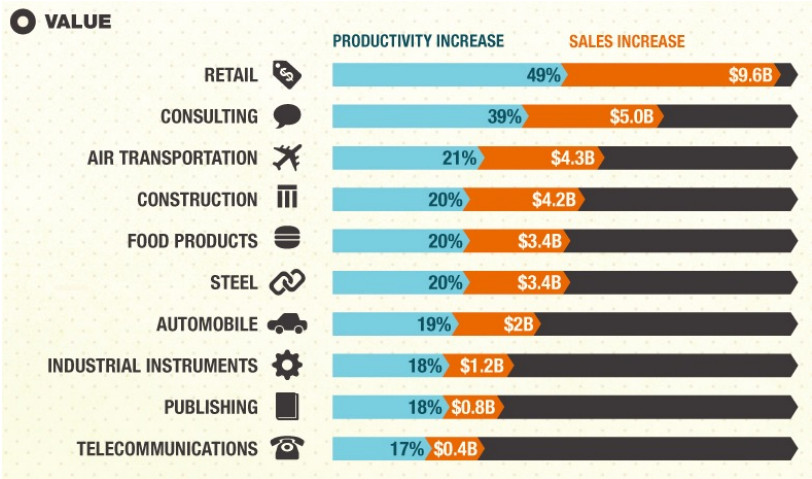
Đặc điểm 5'V của dữ liệu lớn



Dữ liệu lớn là tập dữ liệu quá lợn hoặc là quá phức tạp mà các nền tảng lưu trữ và xử lý dữ liệu truyền thống không đáp ứng được.

17

Dữ liệu lớn – giá trị mang lại lớn



source: wipro.com

18

Khai thác dữ liệu lớn trong giáo dục

- Chương trình học tối ưu, tuỳ biến phù hợp cho người học
- Cải tiến tài liệu, giáo trình phù hợp
- Đánh giá học tập
- Khuyến nghị lộ trình học tập, sự nghiệp



Một vài ví dụ

- **Coursera**
- **VioEdu**
- https://byjus.com/
  - Bài giảng video cá nhân hoá
  - Phân tích tiến độ học tập
  - Các câu hỏi kiểm tra quá trình cá nhân hoá





Khai thác dữ liệu lớn trong khoa học chăm sóc sức khoẻ

- Giảm chi phí điều trị, các xét nghiệm dư thừa
- Dự đoán quy mô đại dịch, khuyến nghị các biện pháp ứng phó
- Ngăn ngừa sớm các bệnh có thể gặp trong tương lai



Khai thác dữ liệu lớn trong quản lý nhà nước

- Các chương trình phúc lợi xã hội
  - Nắm bắt nhanh chóng các vấn đề xã hội (việc làm, tội phạm, môi trường, vvv)
  - Khuyến nghị các biện pháp đối phó
- An ninh thông tin
  - Trốn thuế
  - Lừa đảo

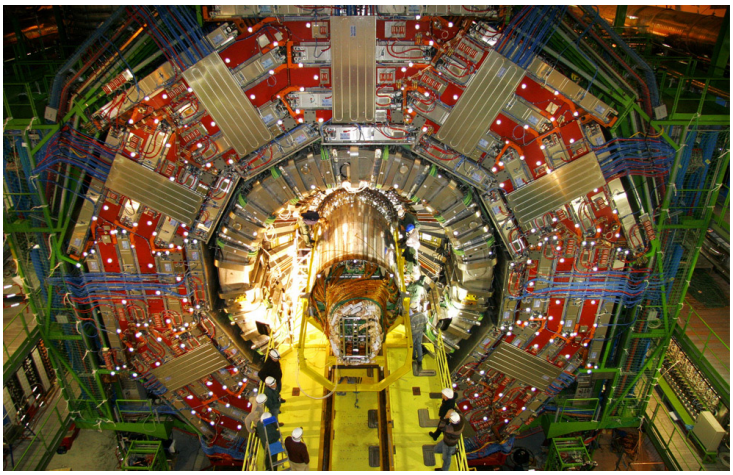


Khai thác dữ liệu lớn trong công nghiệp truyền thông và giải trí

- Dự đoán sở thích của tập khách hàng
- Cá nhân hoá theo sở thích
- Truyền thông bám đuổi mục tiêu hiệu quả
- Ví dụ
  - Spotify, Netflix

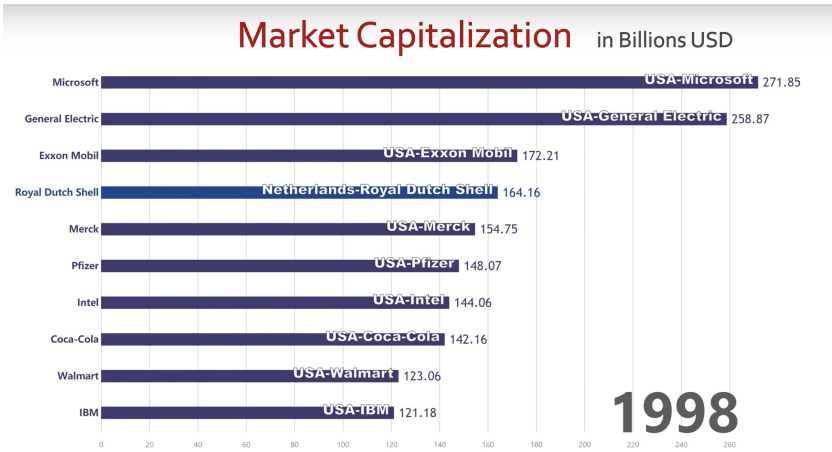


Khai thác dữ liệu lớn trong khoa học khám phá



CERN's Large Hydron Collider (LHC) generates 15 PB a year

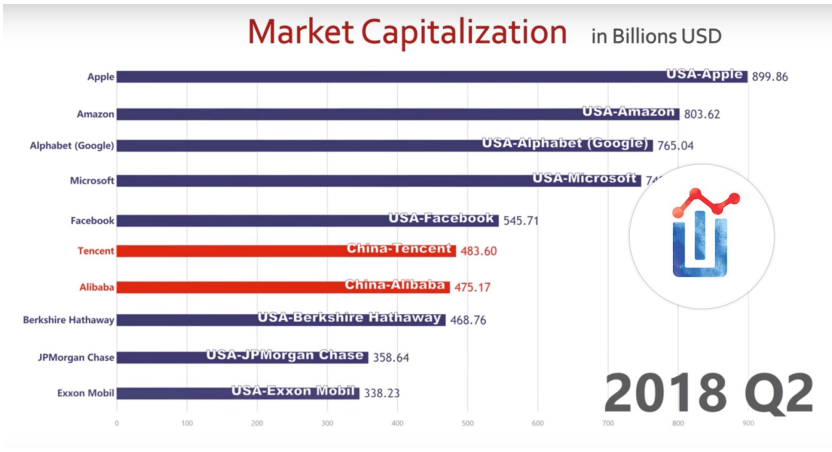
10 công ty lớn nhất (1998-2018)



https://www.youtube.com/watch?v=fobx4wIS6W0

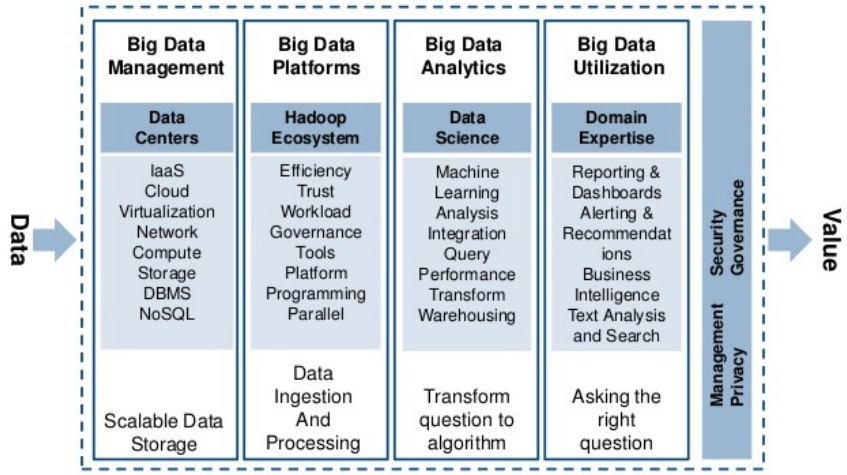
25

10 công ty lớn nhất (1998-2018)



26

Các tầng công nghệ cho dữ liệu lớn



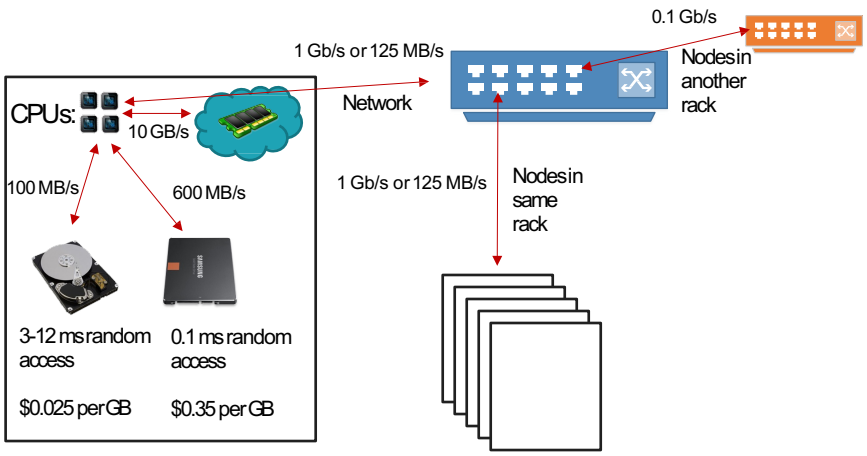
27

Quản lý dữ liệu phải khả mở

- Scalability
  - Khả năng quản lý lượng dữ liệu lớn không ngừng tăng lên theo thời gian.
- Accessibility
  - Cho phép đọc ghi I/O dữ liệu hiệu quả.
- Transparency
  - Truy cập dữ liệu dễ dàng, vị trí lưu trữ dữ liệu trên hệ thống là trong suốt với người dùng cuối.
- Availability
  - Khả năng chống chịu lỗi, khi tăng số lượng người dùng, khi hỏng hóc.

28

Tốc độ I/O phổ biến



Xử lý và tích hợp dữ liệu phải khả mở

- Tích hợp dữ liệu
  - Dữ liệu có định dạng khác nhau
  - Dữ liệu tồn tại ở các mô hình và lược đồ dữ liệu khác nhau
  - Các vấn đề liên quan đến an toàn an ninh thông tin, quyền riêng tư
- Xử lý dữ liệu
  - Xử lý khối lượng dữ liệu rất lớn
  - Xử lý luồng dữ liệu lớn
  - Xử lý dữ liệu song song, phân tán truyền thống (OpenMP, MPI)
    - Phức tạp, khó học
    - Khả năng khả mở có giới hạn
    - Cơ chế chịu lỗi kém
    - Chi phí hạ tầng đắt đỏ
  - Kiến trúc xử lý dữ liệu luồng dữ liệu lớn
    - Spark mini-batch
    - Apache Flink

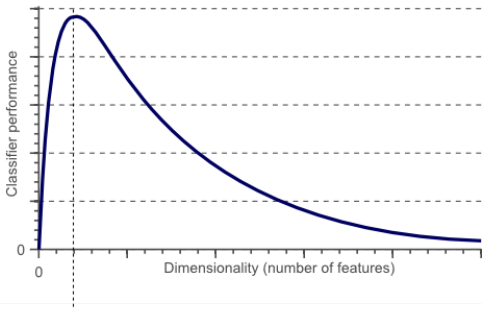
Các giải thuật phân tích dữ liệu khả mở

- Làm nhỏ lại dữ liệu cho phù hợp với các giải thuật truyền thống
  - Eg. Sub-sampling
  - Eg. Principal component analysis
  - Eg. Feature extraction and feature selection
- Song song hoá các giải thuật học máy
  - Eg. k-nn classification based on MapReduce
  - Eg. scaling-up support vector machines (SVM) by a divide and-conquer approach

31

Eg. Sự bùng nổ số chiều trong dữ liệu (Curse of dimensionality)

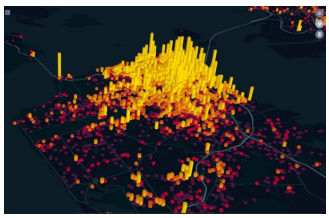
- Số lượng mẫu cần cho mô hình học tăng lên khi số chiều dữ liệu tăng
- Trong thực tiễn: Số lượng mẫu để học thường cố định
  - => Độ chính xác của mô hình giảm khi tăng số chiều trong dữ liệu học

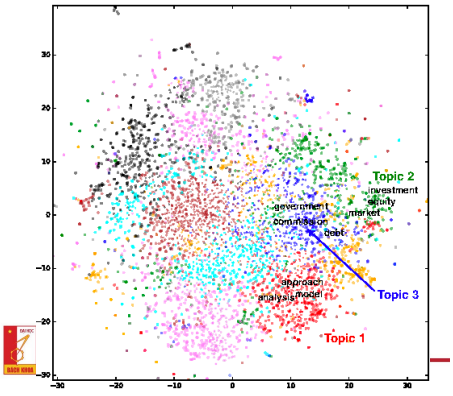


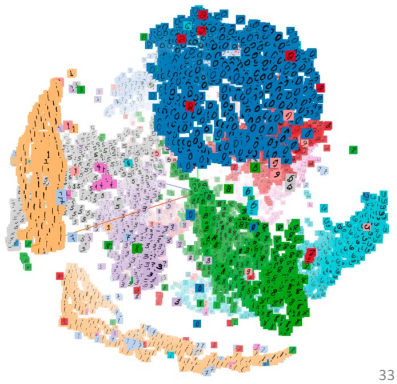
32

Sử dụng và trực quan hoá dữ liệu lớn

- Cần kiến thức chuyên gia
- Cần kỹ thuật và công cụ để hỗ trợ hiệu quả việc trình diễn và hiểu về dữ liệu lớn



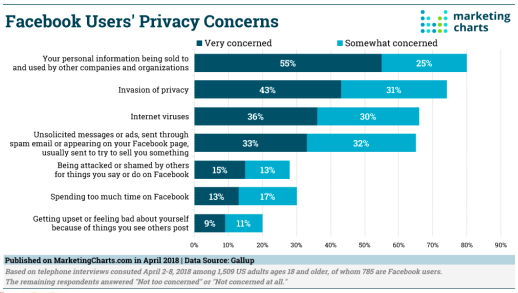


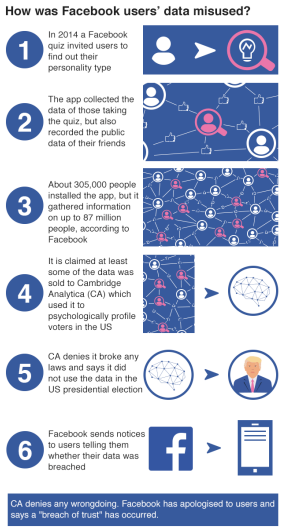


33

Bảo mật và quyền riêng tư

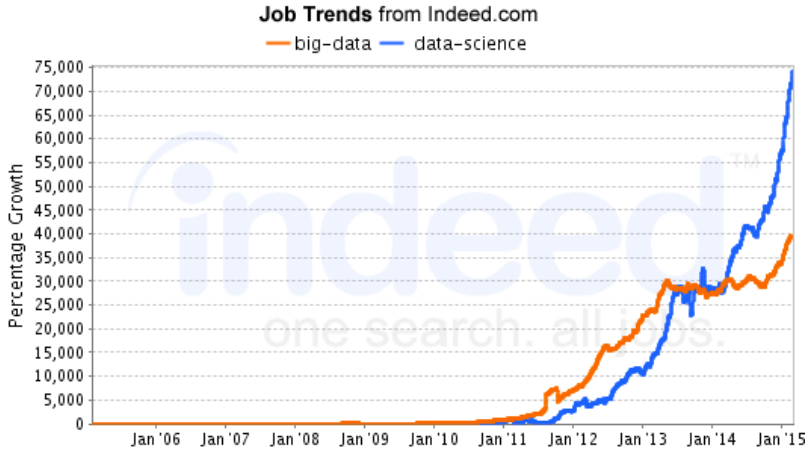






34

Xu hướng nghề nghiệp liên quan tới dữ liệu lớn

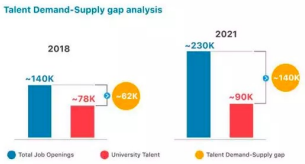


35

Thiếu hụt nhân lực liên quan tới dữ liệu lớn

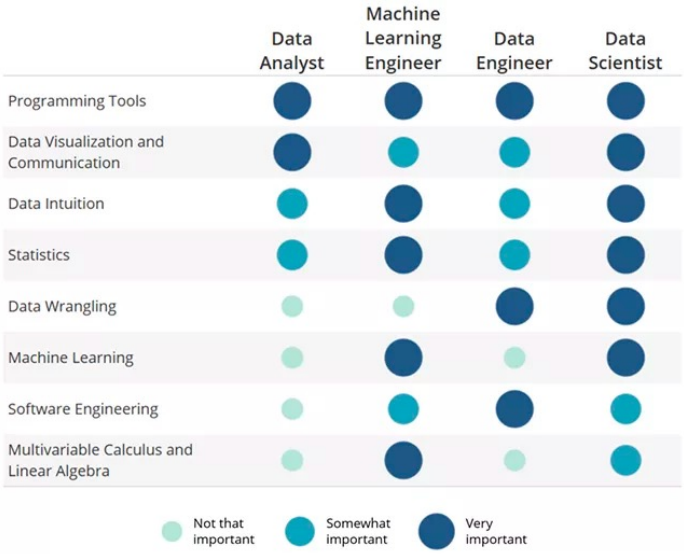
Table 2. Summary Demand Statistics

DSA Framework Category	Number of Postings in 2015	Projected 5-Year Growth	Estimated Postings for 2020	Average Time to Fill (Days)	Average Annual Salary
All	2,352,681	15%	2,716,425	45	$80,265
Data-Driven Decision Makers	812,099	14%	922,428	48	$91,467
Functional Analysts	770,441	17%	901,743	40	$69,162
Data Systems Developers	558,326	15%	641,635	50	$78,553
Data Analysts	124,325	16%	143,926	38	$69,949
Data Scientists & Advanced Analysts	48,347	28%	61,799	46	$94,576
Analytics Managers	39,143	15%	44,894	43	$105,909



36

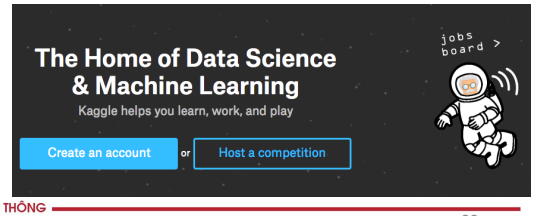
Nhóm các kỹ năng cần thiết theo vị trí



37

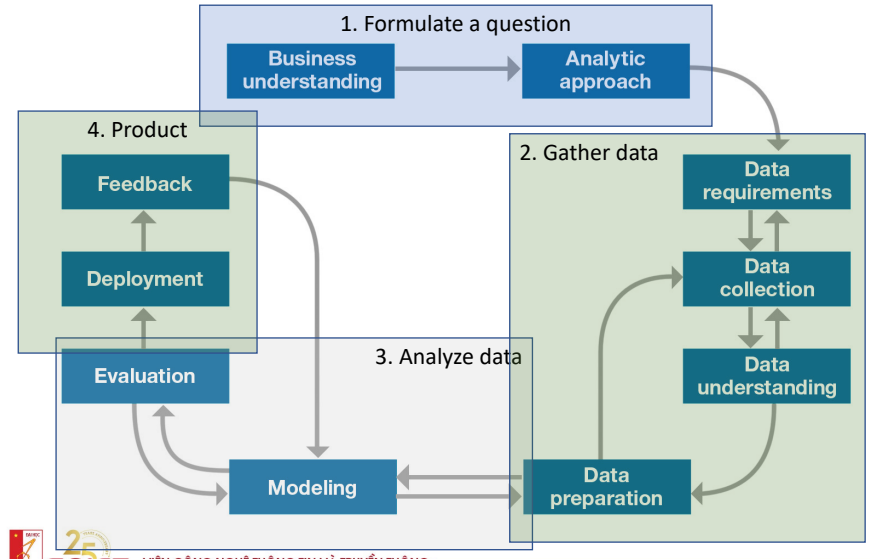
Gợi ý tìm hiểu về dữ liệu lớn

- Học lập trình
  - Coursera
  - Udacity
  - Freecodecamp
  - Codecademy
- Học học máy, toán, toán thống kê
- Kaggle
- Hadoop, NoSQL, Spark
- Các công cụ báo cáo và trực quan hoá
  - Tableau
  - Pentahoo
- Gặp gỡ và chia sẻ
- Tìm cố vấn
- Thực tập, dự án



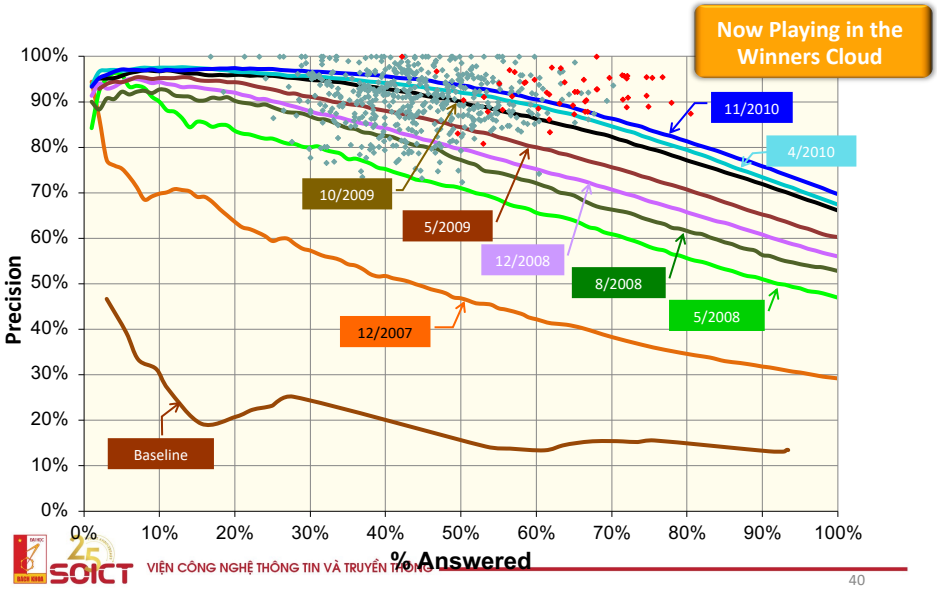
38

Quy trình làm khoa học dữ liệu



39

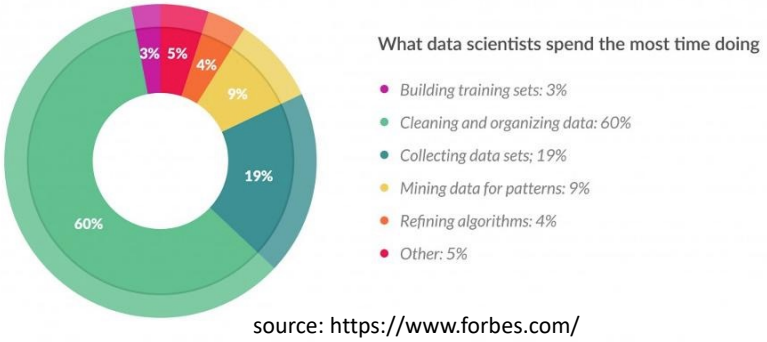
DeepQA: Incremental Progress in Precision and Confidence 6/2007-11/2010



40

Làm sạch dữ liệu lớn: công việc tốn kém thời gian và công sức

- Chiếm khoảng 80% các công việc của nhà khoa học dữ liệu

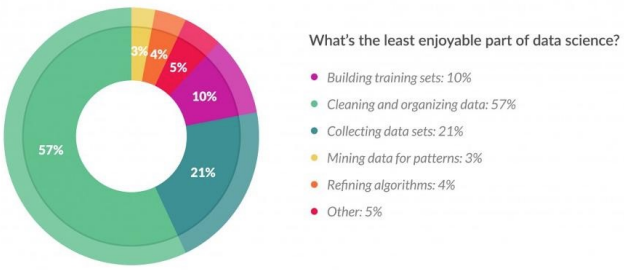


source: https://www.forbes.com/

41

Làm sạch dữ liệu lớn: công việc tốn kém thời gian và công sức

- 57% các nhà khoa học dữ liệu cho rằng đây là công việc kém thú vị



42

Tài liệu tham khảo

[1] Tiwari, Shashank. Professional NoSQL. John Wiley & Sons, 2011.

[2] Lam, Chuck. Hadoop in action. Manning Publications Co., 2010.

[3] Miner, Donald, and Adam Shook. MapReduce design patterns: building effective algorithms and analytics for Hadoop and other systems. " O'Reilly Media, Inc.", 2012.

[4] Karau, Holden. Fast Data Processing with Spark. Packt Publishing Ltd, 2013.

[5] Penchikala, Srini. Big data processing with apache spark. Lulu. com, 2018.

[6] White, Tom. Hadoop: The definitive guide. " O'Reilly Media, Inc.", 2012.

[7] Gandomi, Amir, and Murtaza Haider. "Beyond the hype: Big data concepts, methods, and analytics." International Journal of Information Management 35.2 (2015): 137-144.

[8] Cattell, Rick. "Scalable SQL and NoSQL data stores." Acm Sigmod Record 39.4 (2011): 12-27.

[9] Gessert, Felix, et al. "NoSQL database systems: a survey and decision guidance." Computer Science-Research and Development 32.3-4 (2017): 353-365.

[10] George, Lars. HBase: the definitive guide: random access to your planet-size data. " O'Reilly Media, Inc.", 2011.

[11] Sivasubramanian, Swaminathan. "Amazon dynamoDB: a seamlessly scalable non-relational database service." Proceedings of the 2012 ACM SIGMOD International Conference on Management of Data. ACM, 2012.

[12] Chan, L. "Presto: Interacting with petabytes of data at Facebook." (2013).

[13] Garg, Nishant. Apache Kafka. Packt Publishing Ltd, 2013.

[14] Karau, Holden, et al. Learning spark: lightning-fast big data analysis. " O'Reilly Media, Inc.", 2015.

[15] Iqbal, Muhammad Hussain, and Tariq Rahim Soomro. "Big data analysis: Apache storm perspective." International journal of computer trends and technology 19.1 (2015): 9-14.

[16] Toshniwal, Ankit, et al. "Storm@ twitter." Proceedings of the 2014 ACM SIGMOD international conference on Management of data. ACM, 2014.

[17] Lin, Jimmy. "The lambda and the kappa." IEEE Internet Computing 21.5 (2017): 60-66.

43

Các khoá học trực tuyến

- https://www.coursera.org/learn/nosql-database-systems
- https://who.rocq.inria.fr/Vassilis.Christophides/Big/index.htm
- https://www.coursera.org/learn/big-data-introduction?specialization=big-data
- https://www.coursera.org/learn/big-data-integration-processing?specialization=big-data
- https://www.coursera.org/learn/big-data-management?specialization=big-data
- https://www.coursera.org/learn/hadoop
- https://www.coursera.org/learn/scala-spark-big-data

44

VIỆN CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG
SCHOOL OF INFORMATION AND COMMUNICATION TECHNOLOGY

Chân thành cảm ơn!



soict.hust.edu.vn/ fb.com/groups/soict

45